

Univerzitet u Beogradu

Matematički fakultet

Prepoznavanje aktivnosti pomoću nosivih uređaja za merenje fizioloških parametara

Projekat iz predmeta Istraživanje podataka 2

Bogdan Micić 32/2022

Avgust 2026.

Sadržaj

1	Uvod	3
1.1	Opis strukture skupa podataka	3
1.2	Cilj rada	4
2	Preprocesiranje i analiza podataka	4
2.1	Grupisanje podataka u csv fajl	4
2.2	Podela podataka i analiza atributa	4
2.3	Interpretabilna redukcija skupa atributa	7
2.4	PCA redukcija	10
2.5	t-SNE vizualizacija podataka	10
2.6	LDA redukcija	11
2.7	Zaključak	11
3	Modeli i rezultati klasifikacije	12
3.1	Postupak treniranja i evaluiranja modela	12
3.2	KNN model nad različitim skupovima atributa	14
3.2.1	Analiza rezultata KNN modela nad različitim skupovima atributa	14
3.3	Stabla odlučivanja nad različitim skupovima atributa	16
3.3.1	Analiza rezultata stabla odlučivanja nad različitim skupovima atributa	17
3.4	Naivni Bajes nad različitim skupovima atributa	19
3.4.1	Analiza rezultata Naivnog Bajesa nad različitim skupovima atributa	19
3.5	SVM nad različitim skupovima atributa	20
3.5.1	Analiza rezultata SVM nad različitim skupovima atributa	22
3.6	Neuronske mreže (MLP) nad različitim skupovima atributa	23
3.6.1	Analiza rezultata MLP nad različitim skupovima atributa	24
3.7	Zaključak	26

1 Uvod

Ovaj skup podataka obuhvata sledeća 4 fiziološka merenja (signala):

- ECG (elektrokardiogram) - električna aktivnost srca. Iz njega se izvlače stvari kao srčani ritam i njegova varijabilnost. Srce ubrzava i ritam se menja i pri fizičkom naporu i pri emocijama/stresu, jer sve to aktivira simpatički nervni sistem
- TEB (torakalna električna bioimpedansa) - meri kako se električna otpornost grudnog koša menja u vremenu. To otkriva disanje (pluća se pune vazduhom) i grubo hemodinamiku (protok krvi u grudima). Disanje se menja pri naporu i pri emocijama
- EDA (elektrodermalna aktivnost) - provodljivost kože, tj. znojenje kontrolisano simpatikusom. Klasična mera emocionalnog uzbuđenja/stresa. Ovde je merena zasebno na ruci (nadlaktica) i na šaci, pa imamo dve grupe ovog signala za različiti deo tela

Sve tri vrste merenja hvataju rad autonomnog nervnog sistema - dela koji nesvesno reaguje na uzbuđenje, stres i napor. I na osnovu toga se mogu razlikovati četiri aktivnosti: neutralna, emocionalna, mentalna i fizička.

Ispitanici obavljaju različite aktivnosti u vremenskim prozorima, kako bi se izmerili fiziološki signali. Za neutralnu aktivnost se gleda dokumentarac, za emocionalnu filmovi, za mentalnu aktivnost se rešavaju igre zasnovane na mentalnoj aritmetici i igra Tetris. A za fizičku aktivnost se vršilo trčanje niz stepenice gore-dole.

U merenjima je učestvovalo 40 ispitanika i za svakog postoji 28 merenja od svake aktivnosti zabeleženo. Tako da je skup podataka balansiran po klasama.

1.1 Opis strukture skupa podataka

Skup podataka sadrži 4480 redova i 535 kolona. Od toga su 533 atributa, koji imaju realne, kontinualne vrednosti. Prva kolona predstavlja id ispitanika koji uzima vrednosti od 1 do 40, a poslednja kolona predstavlja oznaku klase i to: 1 - neutralna, 2 - emocionalna, 3 - mentalna i 4 - fizička.

Od 533 atributa, raspodela po vrstama signala je sledeća: 174 ECG atributa, 151 TEB atributa (isto se koristi i oznaka IT u skupu podataka), 104 EDA atributa ruke i 104 EDA atributa šake.

Skup podataka je na osnovu načina merenja već balansiran, kako globalno, tako i na nivou jednog ispitanika. Takođe nema null, NaN ili inf vrednosti.

1.2 Cilj rada

Cilj rada je analizirati skup podataka i pronaći najbolje modele za klasifikaciju podataka u različite klase, odnosno aktivnosti. Time ćemo se bolje upoznati sa samim podacima, pronaći zavisnosti koje važe između različitih signala i merenja i kako su oni povezani sa različitim aktivnostima.


2 Preprocesiranje i analiza podataka

2.1 Grupisanje podataka u csv fajl

Podaci su dostavljeni kao dve datoteke: data.txt koja sadrži podatke i labels.txt koja sadrži nazive kolona. Cilj je objediniti podatke i nazive kolona na jednom mestu, u okviru csv fajla koji je pogodan za tabelarnu. Dodatno, korigovao sam nazive kolona, tako da se razlikuju EDA signali ruke i EDA signali šake koji su imali iste nazive, i ažurirao nazive prve i poslednje kolone.

2.2 Podela podataka i analiza atributa

Podaci se dele na dva skupa, i to trening i test podatke, ali je sama podela malo drugačija od standardne. Klase su same po sebi već balansirane, ali nije dovoljno koristiti stratifikovanu podelu, jer i specifičnost ispitanika ima puno uticaja. Kada bi koristili stratifikovanu podelu, tada bi moglo da se desi da instance koje predstavljaju merenje istog ispitanika za istu aktivnost budu i u trening i u test skupu. Tada model može umesto aktivnosti naučiti ispitanike i njihove specifičnosti, i umesto da prepozna aktivnost na osnovu fizioloških merenja, prepozna da instanca odgovara konkretnom ispitaniku tokom konkretne aktivnosti. Odnosno prepozna ispitanika i poveže ga sa odgovarajućom aktivnošću. Cilj je da klasifikacija bude samo na osnovu fizioloških merenja, odnosno da bude nezavisna od ispitanika, a ne da se modeli pretvore u prepoznavanje ispitanika, umesto aktivnosti. Zato sve podele, i na trening i test skup, i u okviru unakrsne validacije obavljam na način da



Slika 1: Razlike u raspodelama po aktivnosti i po ispitaniku


se jedan ispitanik sa svim svojim redovima može nalaziti ili samo u trening ili samo u test skupu, odnosno samo u validacionom skupu.

Priroda fizioloških merenja jeste takva da zavisi i od konkretnog organizma i kako on specifično reaguje na aktivnosti. Naravno postoje i sličnosti, inače ne bi imalo smisla pričati o klasifikaciji, ali treba napomenuti da specifičnosti ispitanika mogu da utiču na treniranje modela, jer mogu postojati podgrupe ispitanika koje drugačije reaguju na određenu aktivnost od većine.


Primer toga je EDA_Arm_Original_baseline atribut (Slika 1). Može se primetiti dve stvari: postoji razlika u raspodelama medju ispitanicima gde se jasno izdvaja podgrupa ispitanika koja ima nešto veće vrednosti od preostalih, i druga da u raspodeli atributa po klasama postoje autlajeri. Šta ako autlajeri nisu tako nasumični, već su signal koji označava baš podgrupu ispitanika koji imaju povišene vrednosti ovog atributa. To baš pokazuje (Slika 2).

Dakle autlajeri predstavljaju specifične grupe ispitanika, i model je osetljiv na to koji su ispitanici u treningu, pa lako može naučiti specifičnosti određenih grupa i prilagoditi se. Kao rešenje je izvršena normalizacija StandardScaler-om lokalno po ispitanicima, kako bi se umanjile ili eliminisale specifičnosti ispitanika. Ovo se može zasebno uraditi i nad trening i nad test podacima, jer se radi zasebno po ispitaniku, pa nikako ne može doći do curenja informacija iz test skupa. I za slučaj ovog atributa smo uspeli da normalizacijom po ispitaniku uklonimo većinu autlajera i specifičnosti koje dolaze od podgrupa ispitanika koji imaju povišene vrednosti ovog atributa.

Ipak ako posmatramo raspodelu IT_BRV_baseline atributa po klasama, specifičnosti ispitanika se ne otklanjaju (Slika 3). Postoji podgrupa od 6 ispi-



Slika 2: Prikaz autlajera



Slika 3: Prikaz autlajera i bimodalne raspodele atributa

tanika kod kojih je odnos vrednosti atributa u neutralnoj i fizičkoj aktivnosti obrnut. Tako da i ovde autlajeri nisu nasumični, već označavaju podgrupu ispitanika koja reaguje drugačije. Takodje, ovaj atribut ima bimodalnu raspodelu, odnosno dva brega, gde se oko jednog okuplja većina, a oko drugog baš ova podgrupa ispitanika. A sa druge strane, ovo je najinformativniji atribut iz interpretabilne redukcije skupa atributa, o kojem ćemo pričati u nastavku.

Kao zaključak, jasno je da će razdvajanje klasa i treniranje modela biti osetljivo na specifičnosti ispitanika, i da će se najbolje pokazati baš onaj model koji prepozna generalne obrasce dobro, a odbaci ove specifičnosti. Upravo zbog toga, kao polaznu podelu podataka, podatke delimo tako da se ispitanik sa svim svojim redovima nalazi samo u jednoj podeli i kao globalno preprocesiranje podataka na početku normalizujemo skup podataka zasebno po ispitaniku. To radimo sa ciljem da smanjimo specifičnosti ispitanika.


2.3 Interpretabilna redukcija skupa atributa

Interpretabilna redukcija skupa atributa kroz 5 koraka izbacuje manje bitne i redundantne attribute bez transformacije atributa, čuvajući originalne attribute sa ciljem da se smanji dimenzija. Uzimamo prvih (najboljih) 15 atributa po ovoj redukciji. Pre redukcije, je neophodno normalizovati podatke zasebno po ispitaniku. Ona se izvršava u naredna 5 koraka:

1. Odbacujemo one attribute koji imaju varijansu blisku nuli, zato što to znači da gotovo svi redovi imaju konstantnu vrednost tog atributa, pa ne nose značajnu informaciju koja bi razdvajala klase.
2. Računamo uzajamnu informaciju svih atributa. To je nadgledana metoda koja meri koliko saznajemo o ciljnoj klasi ako znamo vrednosti atributa. Za razliku od korelacije sa ciljnom klasom, pored linearnih odlično hvata i nelinearne veze. Mana ove metrike je što svaki atribut gleda izolovano, pa može odbaciti atribut koji jako dobro predviđa klase u kombinaciji sa drugim atributima.
3. Grupišemo medjusobno jako korelisane attribute u klastere hijerarhijskim klasterovanjem. Koristimo Spermanovu korelaciju, jer je robustnija na ekstremne vrednosti i iskošene raspodele i pored linearnih hvata i monotone veze. Ovo radimo zato što postoje velike grupe redundantnih atributa koje efektivno mere istu stvar (ECG_hrv_mean, ECG_hrv_median i ECG_trimmean25 su sve mere centra iste raspodele)
4. Iz svakog klastera biramo onaj atribut koji je najinformativniji, odnosno sa najvećom uzajamnom informacijom.
5. Na kraju ćemo po uzajamnoj informativnosti izdvojiti top 15 atributa, ali takvih da medjusobno nisu jako korelisani, jer hijerarhijsko klasterovanje sa average linkage koji spaja klastere po prosečnom rastojanju ne garantuje da atributi u različitim klasterima nisu medjusobno jako korelisani.

Prvih nekoliko atributa i njihove raspodele po klasama izdvojenih nakon ove redukcije (Slika 4):


Ono što se može primetiti je da prvi, najinformativniji atribut IT_BRV_baseline skoro sam u potpunosti razdvaja skup na tri aktivnosti: neutralna, fizička i




Slika 4: Prikaz nekoliko najinformativnijih atributa nakon redukcije

emocionalno-mentalna. Boxplot-ovi raspodele pri mentalnoj i fizičkoj aktivnosti se ne seku ni sa jednim drugim boxplot-om. Takodje, i preostali atributi jako dobro razdvajaju fizičku aktivnost od preostalih, jer se boxplot fizičke ne seče sa drugima. Ali je svima zajedničko da se raspodele, odnosno boxplot-ovi emocionalne i mentalne aktivnosti preklapaju.


Ono što se može zaključiti na osnovu vizualizacije (Slika 5) i (Slika 6) je da se fizička i neutralna aktivnost lepo razdvajaju, ali da se emocionalna i mentalna aktivnost preklapaju, tako da je pretpostavka da će veliki broj grešaka prilikom klasifikacije dolaziti baš is ovog para aktivnosti. Takodje se na oba grafika može primetiti kako postoje dva klastera neutralne i fizičke aktivnosti, što baš odražava bimodalnu raspodelu atributa IT_BRV_baseline o kojoj smo pričali.



Slika 5: 2D vizualizacija podataka



Slika 6: 3D vizualizacija podataka




Slika 7: 3D vizualizacija podataka nakon PCA

2.4 PCA redukcija

PCA je jedna od osnovnih redukcija atributa koje radimo kako bi smanjili skup atributa, koja pokušava da pronadje medjusobno linearno nezavisne, ortogonalne pravce koji pokrivaju što veće udele varijanse, sve dok zajedno kumulativno ne pokriju svu varijansu. Vodili smo se pravilom da izdvojimo komponente koje opisuju zajedno barem 90% varijanse. Sa Slike 7 se vidi da nakon skoro 50% ukupno objašnjene varijanse, tri komponente već jako dobro razdvajaju fizičku i neutralnu aktivnost, ali ima dosta preklapanja izmedju mentalne i emocionalne aktivnosti.

2.5 t-SNE vizualizacija podataka

t-SNE je stohastičko mapiranje suseda zasnovano na t-raspodeli. Cilj redukcije dimenzionalnosti jeste da se u mapiranju niske dimenzionalnosti sačuva što je moguće više značajne strukture visokodimenzionalnih podataka. Hoćemo da vizualizujemo strukturu podataka, da bi videli da li važi isti obrazac kao i po interpretabilnoj i PCA redukciji, gde se fizička i neutralna aktivnost dobro razdvajaju, a emocionalna i mentalna prepliću. Upravo to i možemo videti na narednom grafiku 8



Slika 8: 2D vizualizacija podataka nakon t-SNE

2.6 LDA redukcija

LDA, linearna diskriminantna analiza, koja transformiše attribute u manji broj komponenti koja poboljšava izražajnost atributa radi bolje klasifikacije i maksimizuje medjuklasne varijanse i minimizuje unutarklasne varijanse. LDA prikazuje koliko su linearno razdvojive klase (Slika 9).

Fizička i neutralna klasa se dobro razdvajaju, ali LDA transformacijom prostora na tri komponente (jer ima četiri klasa, LDA transformiše na 3 komponente) dosta bolje razdvaja emocionalnu i mentalnu aktivnost. Iako aktivnosti nisu potpuni linearno razdvojivi i ima preklapanja, ipak je veći deo jedne aktivnosti iznad druge.

2.7 Zaključak

Radili smo redukciju atributa kako bi smanjili dimenziju podataka, jer je 533 veliki broj atributa. Prokletsvo dimenzionalnosti je problem, naročito prisutan kod modela koji rade sa rastojanjima, gde rastojanja nose dosta manje informacije i smisla kako se broj dimenzija povećava. Modeli se izvrša-

Trening podaci projektovani na tri LDA komponente



Slika 9: 3D vizualizacija podataka nakon LDA

vaju sporije i trening je komplikovaniji nad velikim brojem atributa i veća je šansa da dodje do preprilagodjavanja modela, naročito ako veći deo atributa nije informativan, već nosi šum o nekim specifičnostima vezane za trening podatke.

Kako bi umanjili uticaj prokletstva dimenzionalnosti, koristićemo redukovane skupove atributa, i to nakon interpretabilne redukcije, nakon PCA redukcije, i nakon LDA redukcije. Koristićemo i čitav skup atributa kako bi uporedili modele nad različitim skupovima atributa.

3 Modeli i rezultati klasifikacije

3.1 Postupak treniranja i evaluiranja modela

Skup podataka delimo na trening i test skup, ali grupisano po ispitaniku, tako da se ispitanik sa svim svojim podacima nalazi ili u trening ili u test skupu. Takođe sve podatke koji su za jednog ispitanika zajedno normalizujemo nezavisno od ostalih podataka koji pripadaju ostalim ispitanicima, odnosno normalizujemo lokalno po subjektu. I to radi van pipeline-a i istovremeno i za trening i test podatke, zato što je normalizacija lokalna po ispitaniku (gleda samo redove ispitanika), pa nema curenja informacija iz-

medju trening i test skupa. Ovim je podela nezavisna (ili preciznije manje zavisna) od individualnih ispitanika ili manjih podgrupa medju ispitanicima, a klase koje su globalno balansirane, ostaju balansirane i ovakvom podelom, jer su balansirane i na nivou ispitanika.

Koristimo pipeline konstrukt u okviru kojeg grupišemo sve transformacije podataka i kao poslednji korak sam model koji treniramo. Pipeline je konstrukt koji se koristi u okviru unakrsne validacije tako da se nad trening podacima na svim mestima pozove `fit_transform()` i `fit()` u poslednjem koraku, koji je treniranje modela, a na test podacima (ili podacima iz validacionog skupa) pozove `transform()` ili `predict()` u poslednjem koraku. Jako korisno kada je potrebno grupisati nekoliko transformacija od kojih je neka nadgledana (redukcija atributa bazirana na uzajamnoj informaciji, LDA) ili bi pozivanjem nad celim skupom pre unakrsne validacije već izvršili transformaciju i nad validacionim podacima, pa bi ocena bila veća nego što zapravo jeste jer smo zavirili u validacione podatke.

Koristimo `GridSearchCV`, odnosno pretragu hiperparametara (parametri modela koji su podesivi), kako bi pronašli one najbolje iz pregledanog opsega vrednosti za dati model i podatke (skup atributa). Podelu na delove (fold-ove) radimo preko `GroupKFold`, kako bi i na nivou fold-ova imali raspodelu takvu da je ispitanik ili u trening ili u validacionom skupu, a klase ostaju balansirane i nakon ove podele, jer su klase već lokalno balansirane na nivou ispitanika. Dodatno, postavljamo parametar `shuffle=True`, kako bi ispitanici u okviru trening skupa ili validacionog skupa bili medjusobno izmešani, a da susedni ispitanici koji su možda više medjusobno korelisani ne završe u istom fold-u.

Kao metriku u okviru `GridSearchCV`-a i a generalnu metriku tačnosti i kvaliteta modela koristimo preciznost (`accuracy`) iz razloga što su klase balansirane, pa je metrika validna. Dodatno, za najbolji model iz `GridSearchCV`-a posmatramo i dodatne metrike, kao što su matrica konfuzije, tačnost (`precision`), odziv (`recall`) i f1 mera (`f1-score`). `GridSearchCV` koristimo da bi za svaku kombinaciju model i skup atributa našli odgovarajuće hiperparametre, a potom na test skupu posmatramo kako se model sa najboljim hiperparametrima ponaša na nevidjenim podacima.

Modele ćemo trenirati i upoređivati na četiri skupa atributa i to:

1. skup od 15 atributa nakon intepretabilne redukcije atributa bazirane na uzajamnoj informaciji
2. skup od 44 PCA komponente

3. skup od 3 LDA komponente
4. ceo, originalan skup od 533 atributa

3.2 KNN model nad različitim skupovima atributa

KNN modeli prvenstveno računaju sličnost podataka na osnovu rastojanja, i određuju klasu instance na osnovu klasa najbližih k suseda glasanjem koje može biti i težinsko. Poželjno je podatke normalizovati kako ne bi neki atributi bili važniji od drugih samo zato što su im vrednosti u većim redovima veličine, već se redovi veličine svih atributa izjednačavaju.

Od hiperparametara za KNN model imamo:

1. `n_neighbors`, koji opisuje veličinu blizine, odnosno koliko najbližih instanci posmatrati kao susedi pri odlučivanju (glasanju) kojoj klasi trenutna instanca koja se ispituje pripada
2. `weights`, koji određuje da li glasovi instance (koliko instanca doprinosi određivanju klase) treba da budu jednaki za sve susedne instance, ili ih treba skalirati obrnuto u odnosu na rastojanje od instance, tako da bliže instance imaju veći uticaj na određivanje klase od udaljenijih
3. `p`, koji određuje p u okviru rastojanja Minkovskog, odnosno $p=1$ je Menhetn, a $p=2$ Euklidsko rastojanje

Dodatno, u slučaju PCA transformacije u pipeline-u postoji i parametar `whiten` u pretrazi hiperparametara koji određuje da li podatke nakon PCA transformacije normalizovati (na isti način kao `StandardScaler`) ili ne.

3.2.1 Analiza rezultata KNN modela nad različitim skupovima atributa

Tabela 1: Poređenje performansi KNN nad različitim skupovima atributa

Model	CV Accuracy	Test Accuracy
KNN + 15 atributa	0.8209	0.8080
KNN + PCA	0.7653	0.7679
KNN + LDA	0.7606	0.8024
KNN + ceo skup	0.7709	0.7645

Kao model sa najgorom tačnošću se pokazao model nad celim skupom od 533 atributa, što je donekle i očekivano kao prokletstvo dimenzionalnosti koje se izražava u gubitku značenja i informacija koje udaljenost daje kada se meri nad velikim brojem atributa. A i u 533 atributa ima više onih koji su manje informativni i nose informaciju o specifičnosti ispitanika u trening skupu. Takodje, ni PCA redukcija ne pomaže značajno, što ukazuje da podela po nezavisnim komponentama koje opisuju najveći udeo varijanse ne znači direktno i najbolju podelu podataka po klasama i grupisanje u klastere.

Modeli nakon nadgledanih transformacija atributa su se mnogo bolje pokazali. LDA transformiše podatke tako da maksimizuje medjuklasnu varijansu, a minimizuje unutarklasnu varijansu, sa ciljem da podaci iz iste klase budu što bliži i grupisani u klastere, a klasteri klase što razdvojeniji. Kod LDA se primećuje i skok u tačnosti izmedju modela na unakrsnoj validaciji i modela na test podacima, što ukazuje da se model blago potprilagođava (underfitting), jer LDA nad celim trening skupom više nauči i dodje do komponenti koje još bolje razdvajaju klase, tako da KNN ima veću tačnost. Ovo je nešto što će biti prisutno i u ostalim modelima kao obrazac, gde će postojati skok u oceni izmedju unakrsne validacije i test skupa, kao posledica toga što LDA više nauči nad celim trening skupom koji je veći, pa i napravi komponente koje bolje linearno razdvajaju klase.

Kao model sa najboljom tačnošću nad test podacima se pokazuje model nad 15 atributa dobijenih nakon iterpretabilne redukcije skupa atributa sa parametrima: $n_neighbors = 91$, $p = 1$ i $weights = distance$. Atributi su i izdvojeni po uzajamnoj informaciji, tako da i jesu oni koji svojim vrednostima i najbolje odredjuju klasu. Takodje ih ima 15, odnosno jako malo atributa, i nema redundantnih atributa koji su medjusobno veoma korelisani, što olakšava i omogućava modelu da nauči više i bolje separiše klase. Dok sa više atributa očigledno postoji i više redundantnih i manje bitnih atributa koji svojim vrednostima kao šum odvuku model tako da slabije razdvaja klase, više prilagodivši nekoj podgrupi ispitanika čije su ga ekstremne vrednosti povukle. Takodje parametar $n_neighbors = 91$, koji je najveći medju modelima ukazuje da ovaj model gleda veće grupe i globalnije strukture gde verovatno obuhvata više subjekata, i uspeva da nauči generalnije obrasce i bolje separiše klase od modela nad ostalim skupovima atributa.

Generalno, posmatrajući matricu konfuzije, može se zaključiti da svi modeli dobro razdvajaju podatke u tri klase: fizička, neutralna i emocionalna-mentalna aktivnost. Svi modeli gotovo u potpunosti prepoznaju i razdvajaju fizičku aktivnost od preostalih. Dva najbolja modela i imaju veću tačnost

jer dosta bolje razdvajaju neutralnu aktivnost od preostalih, što znači da preostala dva modela sa više atributa donesu šum zbog kojeg se neutralna aktivnost lošije razdvaja od preostalih.

Većina greške dolazi iz para mentalna-emocionalna aktivnost, što smo i pretpostavili u fazi eksploracije i preprocesiranja podataka. Podaci se ne grupišu u zasebne klastere koji su u potpunosti razdvojeni. I uglavnom se instanca koja je emocionalna pogrešno klasifikuje da je mentalna i obrnuto. Zanimljiva je asimetrija kod najboljeg modela: tu se mentalna aktivnost pogrešno klasifikuje i kao neutralna pored emocionalne, što znači da model sa svim atributima ili modeli gde su atributi izdvojeni po drugačijim kriterijumima mnogo više doprinose razdvajanju mentalna od neutralne aktivnosti, tako da se mentalna aktivnost ne klasifikuje pogrešno kao neutralna.

Dodatno, skoro svugde je pobedilo Menhetn rastojanje, što je i očekivajući rezultat kao rastojanje koje bolje radi i robusnije je na ekstremne vrednosti kada ima više atributa.

3.3 Stabla odlučivanja nad različitim skupovima atributa

Stablo odlučivanja je interpretabilni model treniranja, koji rekurzivno deli podatke po pravilima koja ispituju da li vrednost određenog atributa upada u dati opseg ili ne. Ova pravila se nižu do neke dubine. Listovi određuju klase, i to ona klasa čije su instance u toku treninga većinski završili u tom listu.

Hiperparametri modela:

1. `criterion`, mera nečistoće na nivou čvora koja određuje koja podela će se uzeti
2. `max_depth`, maksimalna dubina stabla, glavni hiperparametar koji određuje koliko će stablo narasti. Što veća dubina, znači veće stablo koje bolje uči o podacima, tako da gotovo uvek ako ne ograničimo dubinu ili postavimo preveliku vrednost dolazi do preprilagodjavanja modela
3. `min_samples_leaf`, minimalan broj uzoraka (instanci) u listu
4. `ccp_alpha` (cost-complexity pruning), parametar regularizacije, koji nakon rasta stabla radi potkresivanje i seče grane za koje vidi da se

ne isplate

5. `max_features`, parametar regularizacije, koji za svaki čvor nezavisno izvlači podskup atributa koji će da posmatra i iz kojeg će da pronalazi najbolju raspodelu

3.3.1 Analiza rezultata stabla odlučivanja nad različitim skupovima atributa

Tabela 2: Poređenje performansi Stabla Odlučivanja nad različitim skupovima atributa

Model	CV Accuracy	Test Accuracy
Stablo + 15 atributa	0.9297	0.8929
Stablo + PCA	0.7598	0.7087
Stablo + LDA	0.7603	0.7656
Stablo + ceo skup	0.8889	0.9107

Stablo odlučivanja je nad originalnim atributima i atributima nakon interpretabilne redukcije znatno bolji od KNN-a, a nad projekcijama je lošiji. Uzrok je u tome što ta dva modela traže suprotne stvari u podacima.

KNN gleda rastojanje, koje sabira doprinose svih atributa podjednako, pa ga nebitni atributi uguše - zato mu je pun skup bio najlošiji ulaz, a redukcija je pomogla. Stablo, nasuprot tome, u svakom čvoru bira jedan atribut i jedan prag; nebitni atributi jednostavno nikada ne budu izabrani i ne koštaju ništa. Zato veći broj atributa stablu daje samo više prilika da nadje dobar prag, pa je puni skup od 533 atributa njegov najbolji ulaz, dok mu redukcija na 15 atributa oduzima kandidate za podelu.

Isto objašnjenje važi i u drugom smeru: PCA i LDA komponente su guste linearne kombinacije svih 533 atributa, u kojima više ne postoji "prag na jednom merenju". Podela po jednoj komponenti u originalnom prostoru odgovara kosoj hiperravni, a to je bas ono što stablo ne ume da gradi - može samo da je aproksimira stepeničasto. Zato projekcije, koje su KNN-u pomagale da sažme prostor, stablu odnose bas onu strukturu na kojoj počiva.

Dva najbolja modela stabla odlučivanja gotovo u potpunosti razdvajaju emocionalnu i mentalnu aktivnost sa visokim f1 merama, tako da par mentalna-emocionalna aktivnost ovde nije problematična. Kao razlog zbog

čega, primetili smo u eksploraciji i pretprocesiranju podataka da postoje atributi koji imaju bimodalne raspodele (sa više bregova), i da postoje podgrupe ispitanika čije se vrednosti atributa grupišu oko različitih bregova. Verovatno postoji dosta takvih atributa, gde je teško generalizovati i naučiti takve raspodele vrednosti i na osnovu njih naučiti kako razdvajati klase, a verovatno baš takvi atributi nose informaciju o podeli na emocionalnu ili mentalnu aktivnost. Stabla odlučivanja su jedan od najboljih modela baš za slučaj atributa sa bimodalnim raspodelama i više podslučajeva, gde čvorovima (pravilima) blizu korena podele instance na podslučajeve, i onda traže dalje podele sa najmanjim nečistoćama (koje najbolje dele klase) u svim podslučajevima zasebno. I baš zato stabla odlučivanja ostvaruje visoke rezultate tačnosti.

Kada upoređujemo dva najbolja modela, model sa svim atributima je zapravo jednostavniji, ima manje listova i manje je dubine. To se upravo nadovezuje da mu je više atributa dalo prostora za više različitih podela koje su kasnije rezultovale boljim potkresivanjima. Model sa svim atributima bolje razdvaja emocionalnu i mentalnu aktivnost od preostalih, i postoji simetrija u razdvajanju i greškama u paru emocionalna-mentalna aktivnost. U modelu sa 15 atributa očigledno hvale atributi na osnovu kojih može bolje da razdvaja emocionalnu aktivnost od preostalih, gde je pored mentalne ponekad meša i sa fizičkom aktivnošću. Kao i u slučaju KNN modela sa 15 atributa, i ovde stablo odlučivanja mentalnu aktivnost meša sa neutralnom (manje nego u slučaju KNN), ali se može izvući zaključak da u skupu od 15 atributa hvale atributi koji bi dali informaciju kako da se razdvoji mentalna od neutralne aktivnosti. Ili se takodje može pretpostaviti da i u test podacima postoji podgrupa ispitanika kod kojih su mentalna i neutralna aktivnost drugačije razdvajaju i neutralna aktivnost dosta bliža mentalnoj nego kod preostalih ispitanika.

Ako posmatramo grafike stabla odlučivanja za dva najbolja modela, možemo primetiti da su pri vrhu, blizu korenu ali i većinski kao čvorovi zastupljeni atributi koji mere različita svojstva IT signala (ujedno je i najbitniji atribut iz interpretabilne redukcije atributa i na osnovu uzajamne informacije baš IT signal).

Dodatno, oba dva najbolja modela, i onaj nad celim skupom atributa, i onaj nad redukovanim skupom od 15 atributa ne razdvaja gotovo idealno fizičku aktivnost, što je drugačije od najboljeg KNN modela. Uzrok je priroda oštih pragova: stablo pravi granicu na jednoj vrednosti, pa nekoliko redova neposredno uz prag padne na pogrešnu stranu, dok KNN sa velikim susedstvom ($k=91$) tu istu odluku donosi glasanjem i granične slučajeve izgadi.

3.4 Naivni Bajes nad različitim skupovima atributa

Naivni Bajes je jednostavan model, zasnovan na Bajesovoj teoremi, gde za svaku od klasa računa uslovnu verovatnoću da je pri tim vrednostima atributa instanca baš o toj klasi, i od svih uslovnih verovatnoća bira onu najveću i ta klasa je rezultat klasifikacije jedne instance. Ono što je naivno u algoritmu je pretpostavka da su raspodele atributa nezavisne u okviru klase. Iako ova pretpostavka gotovo nikad nije tačna, Naivni Bajes i dalje dobro klasifikuje, jer je za dobru klasifikaciju bitniji tačan poredak uslovnih verovatnoća od tačnih vrednosti uslovnih verovatnoća.

U scikit-learn biblioteci postoji više varijanti Naivnog Bajesa, a kako su atributi kontinualne vrednosti, biramo GaussianNB, uz koji dodatno ide pretpostavka da su raspodele atributa normalne. Kako bi raspodele atributa transformisali tako da budu što bliže normalnoj raspodeli, u pipeline dodajemo kao opciju i PowerTransformer(method="yeo-johnson") transformaciju atributa koja popravljja iskošenost u raspodelama tako da raspodele atributa budu što bliže normalnoj.

Jedini hiperparametar u okviru GaussianNB je var_smoothing parametar, koji određuje udeo najveće varijanse među svim atributima koji se dodaje svim varijansama, čime se u većoj ili manjoj meri razmazuju naučene normalne raspodele zavisno od toga koliko su korisne ili štetne.

Dodatno, prep se pojavljuje kao hiperparametar, a određuje transformaciju koja će se izvršiti na početku. Odnosno, PowerTransformer(method="yeo-johnson") ili ništa i PowerTransformer(method="yeo-johnson") ili StandardScaler(). PowerTransformer(method="yeo-johnson") takodje normalizuje podatke nakon ispravljanja iskošenosti raspodela atributa.

3.4.1 Analiza rezultata Naivnog Bajesa nad različitim skupovima atributa

Tabela 3: Poređenje performansi Naivnog Bajesa nad različitim skupovima atributa

Model	CV Accuracy	Test Accuracy
GaussianNB + 15 atributa	0.7087	0.6741
GaussianNB + PCA	0.7899	0.7779
GaussianNB + LDA	0.7583	0.8013
GaussianNB + ceo skup	0.7729	0.7846

Naivni Bajes nad skupom od 15 atributa daje dosta nižu tačnost od modela na preostalim skupovima atributa. Razlog tome je što i pored PowerTransformer (method='yeo-johnson') koja ispravlja iskošenost nije moguće ukloniti više bregova u okviru atributa koji imaju bimodalne raspodele (kakav je najinformativniji IT_BRV_baseline u okviru fizičke aktivnosti, a verovatno i još neki ili većina), pa uslov normalnosti raspodela atributa po klasama nije zadovoljen zbog čega i dolazi do lošijih rezultata. Na to ukazuje i visoka vrednost var_smoothing parametra koja znači da naučene normalne raspodele su štetne i bolje ih je razmazati, odnosno poništiti. Uslov nezavisnosti ne bi trebalo da je u velikoj meri narušen, jer je poenta redukcije da se izdvoje atributi koji su međusobno slabije korelisani.

Naivni Bajes nad celim skupom atributa i nad PCA komponentama se ponaša slično. U slučaju celog skupa malo bolje razdvaja neutralnu aktivnost, ali je odziv emocionalne aktivnosti jedan od generalno najnižih (0.56) i dosta niži od modela nad PCA komponentama, ali odziv mentalne aktivnosti viši (0.76). Kod modela sa PCA komponentama je slučaj obrnut, bolje hvata emocionalnu aktivnost (odziv je veći), a mentalnu lošije.

Model postiže najveću tačnost nad LDA komponentama, uz isti obrazac da je model bolji kada se LDA transformacija izvrši nad čitavim trening skupom i daje bolje rezultate na test skupu.

I dalje važi da je većina greške kod modela nad svim skupovima atributa bas u problematičnom paru emocionalna-mentalna aktivnost koji se ne mogu lako razdvojiti.

3.5 SVM nad različitim skupovima atributa

SVM je klasifikator koji traži hiperravan čije granice su instance, i to takvu da je rastojanje do najbližih tačaka najveće. To rastojanje, koje se maksimizuje, se naziva margina. Tačke (instance) koje su na granici hiperravni (leže na margini), ili je krše i unutar su granice se nazivaju support vektori, i samo oni određuju model, dok ostatak podataka može da se izbriše bez izmene rešenja. Pošto su podaci retko kad savršeno razdvojivi, koriste se soft (meke) margine koje dopuštaju kršenja margine i da neke instance budu unutar margine.

SVM je originalno klasifikator koji pokušava da linearno razdvoji klase i radi odlično ukoliko su klase linearno razdvojive. U slučaju da nisu, postoji kernel trik: u izračunavanju margine podaci jedino učestvuju u okviru skalarnog proizvoda, pa je moguća zamena skalarnog proizvoda funkcijom koja

računa skalarni proizvod u novom prostoru u kojoj transformišemo nelinearno razdvojive podatke tako da budu linearno razdvojivi, ali bez eksplicitne transformacije podataka. Zbog toga ćemo kao kernel, pored linearnog koristiti i rbf, koji formira fleksibilne, zatvorene i zakrivljene granice.

Kako SVM koristi meru rastojanja kako bi odredio marginu, normalizacija podataka pre upotrebe SVM je obavezna. Dodatno, posmatraćemo i udeo instanci koje su support vektori, gde veliki udeo označava preprilagodjavanje modela.

Hiperparametri:

1. kernel: funkcija koja računa skalarni proizvod podataka u transformisanom prostoru (koji neretko ima više ili beskonačno dimenzija) u kojem su podaci linearno razdvojivi, ali se ta granica preslikava u neku nelinearnu krivu u početnom prostoru, i to bez eksplicitnog transformisanja podataka. Koristićemo linearni i radijalni kernel, odnosno linear i rbf kernel.
2. C: inverzna jačina regularizacije, koja određuje koliko se instanci dozvoljava koje krše marginu. Malo C znači široku marginu i više dozvoljenih grešaka, pa time i jednostavniji model, gde može doći do podprilagodjavanja. Veliko C znači malu, usku marginu i model se trudi da klasifiku svaki uzorak tačno, pa lako može doći do preprilagodjavanja.
3. gamma: širina RBF kernela, nije hiperparametar za linearni kernel. Određuje domet uticaja jednog support vektora, gde oko svakog support vektora, zavisno od vrednosti gamma, postavlja zonu uticaja. Ukoliko je gamma malo, prave se široke zone i tačka utiče daleko od sebe. A ukoliko je gamma veliko, uske zone i uticaj tačke opada veoma brzo, gotovo odmah čim se odmaknemo od nje. Malo gamma daje razlivene granice, koje su skoro prava linija, pa se model efektivno i degeneriše u linearni klasifikator i ne nauči lokalne strukturne zavisnosti koje nisu linearne, pa dodje do podprilagodjavanja. Veliko gamma pravi ostrvca oko support vektora, pa granica bude naborana i isprekidana i dolazi do preprilagodjavanja. Zbog toga nema neke univerzalno dobre vrednosti za gamma, traži se u kombinaciji sa parametrom C. Kako je gamma u slučaju rbf kernela dimenziono inverzan kvadratu rastojanja, a kvadratno rastojanje obično raste linearno sa dimenzijom podataka (brojem atributa), raspon vrednosti gamma i određujemo zavisno od dimenzije skupa atributa na kojem treniramo model.

3.5.1 Analiza rezultata SVM nad različitim skupovima atributa

Tabela 4: Poređenje performansi SVM nad različitim skupovima atributa

Model	CV Accuracy	Test Accuracy
SVM + 15 atributa	0.7840	0.7790
SVM + PCA	0.8348	0.8304
SVM + LDA	0.7559	0.7924
SVM + ceo skup	0.8306	0.7433

Ni kod jednog SVM modela nije pobedio linearni kernel. Kod modela nad PCA komponentama i nad celim skupom atributa je uz rbf kernel izabrana najmanja vrednost gamma u mreži. To znači da njima ne treba jaka nelinearnost, ali im treba malo nelinearnosti. Takodje kada pogledamo matrice konfuzije, i dalje najveća greška dolazi od para mentalna-emocionalna aktivnost. Ovo se slaže sa onim što smo pretpostavili iz 2D i 3D vizualizacije podataka, da klase, a posebno par emocionalna-mentalna aktivnost nisu razdvojive linearnom granicom.

SVM model nad celim skupom atributa ima drugu najbolju tačnost na unakrsnoj validaciji (odmah iza PCA), ali najgoru tačnost na test skupu. Matrica konfuzije pokazuje da neutralna klasa postaje podrazumevana, jer u nju udje 93 instanci koje nisu neutralna, pa i pored velikog odziva 0.88 joj preciznost opadne na 0.68. Takodje je i odziv fizičke klase jedan od najlošijih, jer je uglavnom iznad 0.9, i često blizu jedan, jer smo iz vizualizacija podataka mogli da zaključimo da se fizičke aktivnosti prirodno grupišu u klaster koji je udaljeniji od ostalih aktivnosti, pa uglavnom svi modeli nad svim skupovima atributa gotovo idealno razdvajaju fizičku aktivnost od preostalih. Ovo je posledica prokletsva dimenzionalnosti. Od 533 atributa, samo mali deo nosi informaciju o aktivnosti, a većina nose preostalu strukturu specifičnu za ispitnike u trening skupu, zbog čega i dolazi do preprilagodjavanja modela.

SVM model kod LDA ponavo ukazuje na isti obrazac, model ima veću ocenu na testu, nego na unakrsnoj validaciji. To ukazuje da unakrsna validacija potcenjuje model, i da uticaj bolje naučene LDA transformacije nad većim trening skupom nije zanemarljiva. LDA je i sam linearni klasifikator, tako da ako može bolje da nauči prostor i transformiše ga na način da klase budu više linearno razdvojive, modeli koji bolje rade sa podacima koji su bliže linearno razdvojivi prosperiraju, i daju veću tačnost na test skupu kada je i LDA transformacija bolje naučila podatke nad većim trening skupom. Naivni

Bajes i SVM generalno rade bolje nad podacima koji su linearno razdvojivi, dok LDA odmaže stablu odlučivanja, jer transformiše prostor na način koji ne pomaže stablu odlučivanja. Atributi su sada linearne kombinacije puno atributa, tako da podele viže nisu po jednom atributu, nego uzimaju puno originalnih atributa istovremeno i dosta smanjuje skup atributa, pa i mogućih podela.

Kao model sa najboljom tačnošću se pokazao PCA. Ujedno je i jedan od najstabilnijih izbora, jer je jako mala razlika između tačnosti na unakrsnoj validaciji i test skupu. Model nad PCA bira gamma 100 puta manje od podrazumevanog, što daje glatku granicu, a uz to ima i najveći udeo support vektora. Ipak ne dolazi do prilagodjavanja ili podprilagodjavanja, već malo gamma koje daje široko jezgro i umerena vrednost C ($C = 10$), daju široke i glatke granice gde većina support vektora leži na margini.

Kod modela sa interpretabilnim skupom od 15 atributa se ne zabeležava dobra tačnost (ispod 0.8) i na unakrsnoj validaciji i test skupu. Zanimljivo je da je ovde odabrana najuža širina jezgra od izabranih, uz blagu regularizaciju ($C = 10$). To može da objasni nižu tačnost, gde se struktura specifična za subjekte javlja i u tom skupu od 15 atributa, pa sa malim granicama jezgra se pokupi više specifične strukture tako da se model prilagodi u toku treniranja, pa ne bude toliko precizan na novim podacima koje nije video, što se može i videti na osnovu tačnosti trening podatak koja je 0.97, dosta veća od tačnosti na test podacima (0.78).

3.6 Neuronske mreže (MLP) nad različitim skupovima atributa

Neuronska mreža MLP (Multy-layer perceptron) je neuronska mreža u scikit-learn biblioteci koja ima jedan ulazni sloj koji ima onoliko neurona koliko i atributa, jedan ili više skrivenih slojeva i izlazni sloj, koji u slučaju klasifikatora odgovara broju klasa. Svaki neuron računa težinsku sumu ulaza plus bias, pa na to primeni nelinearnu aktivacionu funkciju čiji rezultat je izlaz neurona. Nelinearne aktivacione funkcije omogućavaju neuronskoj mreži da nauči nelinearne granice između klasa. Učenje ide propagacijom unazad, gde se greške računaju na izlazu, propagiraju unazad kroz slojeve lančanim pravilom i težine ažuriraju gradijentnim spustom. Kao aktivaciona funkcija u izlaznom sloju se u scikit-learn biblioteci automatski stavlja na softmax u slučaju višeklasne klasifikacije (naš slučaj), a kao funkcija gubitka se uzima

unakrsna entropija.

Hiperparametri:

1. `hidden_layer_sizes`: koji određuje arhitekturu mreže, koliko će biti slojeva i koliko neurona na svakom od njih. Izbor je načinjen tako da odgovara broju atributa na ulazu, gde je arhitektura veća za ulaz sa svim atributima, a manja za ulaze sa manje atributa
2. `alpha`: dodaje kaznu za velike težine (pri malim promenama ulaza dolazi do velikih promena izlaza), kako mreža ne bi minimizovala samo unakrsnu entropiju, gde bi u tom slučaju velike težine pravile oštre, izlomljene promene koje bi se prilagođavale pojedinačnim trening instancama. Sa `alpha` kaznom velikih težina, dobijamo glatkije promene i glatkije funkcije
3. `learning_rate_init`: određuje korak učenja, u kojoj meri uzimamo novi rezultat ili se više oslanjamo na stari rezultat. Premali korak, spora konvergencija i model se zaustavlja ograničen brojem epoha i ne dođe do konvergencije. Prevelik korak, optimizacija preskače minimum, gubitak osciluje (pa sporije konvergira) ili divergira
4. `activation`: vrsta aktivacione funkcije, `relu` je podrazumevan izbor zbog jednostavnog računanja izvoda, ali ćemo probati i `tanh`

Kako su i `alpha` i gradijentni spust osetljivi na različite redove veličina atributa, normalizacija podataka pre upotrebe modela je obavezan korak.

3.6.1 Analiza rezultata MLP nad različitim skupovima atributa

Tabela 5: Poređenje performansi MLP nad različitim skupovima atributa

Model	CV Accuracy	Test Accuracy
MLP + 15 atributa	0.8666	0.8583
MLP + PCA	0.8276	0.8348
MLP + LDA	0.7553	0.7902
MLP + ceo skup	0.8376	0.7511

MLP je najbolji model koji nije stablo odlučivanja. I to treći najbolji model nakon stabla odlučivanja nad celim skupom i interpretabilnim skupom

od 15 atributa. MLP model nad interpretabilnih 15 atributa je najbolji ulaz i na osnovu tačnosti sa unakrsne validacije i na osnovu tačnosti iz test podataka. Takodje ovo je prvi model koji nakon stabla odlučivanja ima pomak u razdvajanju para mentalna-emocionalna aktivnost, gde je prosečan odziv na nivou para ovde 0.785, a inače su svi ostali modeli bili zaglavljani oko 0.72 i niže.

Ovo je prvi model gde se skup atributa poklapa sa drugim modelom, odnosno sa KNN-om. I to nije slučajno, jer i MLP i KNN polaze od svih ulaza istovremeno i moraju da sami nauče koji su bitni. KNN nema nikakav mehanizam da odredi bitne attribute, a MLP mehanizmom regularizacije prilikom optimizacije određuje bitne težine, ali trošeći podatke prilikom čega gasi određene ulaze, ali nasuprot stablima koji direktno biraju attribute, MLP to ne radi direktno i radi sporije. Zato obojici pomaže kada je izbor atributa već obavljen, i obojici odgovara kada se nekako izdvajaju najinformativniji originalni atributi, bez transformacija. Stablu takav izbor ne treba, jer on to već radi sam usput, a kod Naivnog Bajesa smo videli da izbor atributa na osnovu uzajamne informacije smeta, jer kriterijum ne mari za oblik raspodele, pa uslov normalnosti nije ispunjen.

I kod MLP nad LDA komponentama se ponavlja obrazac, gde unakrsna validacija potcenjuje model, pa je bolja tačnost na test skupu, jer je LDA transformacija naučena na celom skupu trening podataka, koji obuhvata više ispitanika nego trening skup po fold-ovima u unakrsnoj validaciji.

Kod MLP nad celim skupom od 533 atributa dolazi do preprilagođavanja modela. Od 533 atributa samo mali deo nosi informaciju o aktivnosti, a ostatak nosi strukturu specifičnu sa ispitanike (normalizacija po ispitaniku, pa potom globalna normalizacija je ublažila ovaj negativan efekat, ali ga nije otklonila). Zato je model osetljiv na to koji su ispitanici u trening skupu i sa puno atributa više nauči ispitanike nego li aktivnosti, zbog čega daje lošiju tačnost na test skupu.

MLP nad PCA komponentama je takodje dobar, malo lošije tačnosti od modela nad skupom od 15 atributa, ali i dalje generalno jedan od boljih modela kada se uporedi i sa ostalim modelima. Sličan je po tačnosti SVM modelu nad PCA komponentama, i uz njega model sa najboljom tačnošću nakon stabla i MLP nad skupom od 15 atributa.

Aktivaciona funkcija tanh pobedjuje na malim ulazima i relu na velikim. To je zato što relu funkcija često gasi određene ulaze prilikom optimizacije, i to je isplativije za ulaze sa dovoljno velikom dimenzijom, odnosno dovoljno atributa, dok je u malim ulazima glatka i ograničena tanh stabilnija funkcija.

Takodje alpha raste sa dimenzijom ulaza, što je i za očekivanje, jer više ulaza pravi više težina od kojih nisu sve korisne, pa je potrebna jača kazna.

3.7 Zaključak

Ni jedan skup atributa nije dominantno korišćen u odnosu na druge. Svaki od skupova je upotrebljen barem jednom. To znači da svaki skup atributa bolje odgovara odredjenom modelu. Ipak dva modela koja se izdvajaju visokom tačnošću su stabla odlučivanja nad celim skupom i stabla odlučivanja nad redukovanim skupom od 15 atributa. Ta dva modela najbolje razdvajaju problematičan par aktivnosti emocionalna-mentalna. Pokazuju da su uslovna pravila najbolja za razdvajanje klasa, što je verovatno posledica toga da najinformativniji atributi imaju bimodalne raspodele koje su posledica više različitih podgrupa ispitanika sa sličnim vrednostima pri odredjenim aktivnostima. A uslovna pravila najbolje razdvajaju podslučajeve, gde se svaki od podslučajeva zasebno može dalje deliti uslovnim pravilima sve dok se dobro ne razdvajaju klase. MLP je takodje sposoban da nauči složene granice, zbog čega je malo lošiji od stabla odlučivanja, ali bolji od ostalih modela. Ipak, granica klasa i naročito razdvajanje problematičnog para aktivnosti emocionalna-mentalna nije pitanje linearnosti i nelinearnosti. Uslovna pravila su ta koja doprinose najviše razdvajanju klasa, i naročito para emocionalna-mentalna aktivnost, pa su na kraju stabla odlučivanja i najbolji izbor kao model za ovaj slučaj klasifikacije.